Pergunta de classificação - Fintech Guard

Integrante A | TP3 | Revisão: 17/10/2026

Tarefa e recorte do projeto

Dado o texto de uma mensagem, seu conteúdo pertence à classe benigno ou apresenta uma ameaça de engenharia social, conforme os rótulos do dataset? A unidade de análise é uma mensagem; a entrada é texto, e a saída planejada é uma classe de segurança para apoiar triagem.

O Fintech Guard reúne atendimento bancário e proteção contra engenharia social. Este documento adapta a pergunta de intenções do enunciado ao componente de segurança estudado no TP1 e TP2. **Conteúdo ameaçador e intenção do remetente são conceitos distintos:** um cliente legítimo pode relatar ou citar uma tentativa de phishing. O classificador proposto não comprova intenção maliciosa, fraude ou identidade e não autoriza transações.

As classes abaixo não representam pedidos de fatura, cancelamento ou investimento. O roteamento de intenções de atendimento é uma tarefa complementar, que exigiria outro protocolo com BANKING77; as duas bases não serão misturadas. O plano conjunto deve registrar o alinhamento desse recorte com o integrante B e a orientação da disciplina. Não se presume aprovação específica dessa adaptação.

Dados, classes e distribuição

Fonte: dataset de segurança descrito em docs/dataset_security.md. Dos 624 registros reconstruídos, foram excluídas 15 linhas com rótulos conflitantes e seis duplicatas excedentes, restando 603 mensagens em inglês. As definições são operacionais; há sobreposição entre categorias.

Classe original	Definição operacional	n	%
NOT-Malicious General Class	Conteúdo benigno segundo o dataset	171	28,36
Phishing	Indução a fornecer dados ou acessar conteúdo fraudulento	110	18,24
Scareware	Medo ou urgência para induzir uma ação	100	16,58
Baiting	Prêmio ou benefício usado como isca	80	13,27
Malware	Indução a instalar ou executar conteúdo malicioso	77	12,77
Pretexting	Pretexto ou identidade alegada para obter cooperação	65	10,78
Total		**603**	**100,00**

Proposta para T2: classificação binária principal, benigno (171; 28,36%) versus ameaça (432; 71,64%), agrupando as cinco categorias de ameaça. Ameaça será a classe positiva. Essa escolha reduz a fragmentação de uma amostra pequena, mas não elimina desbalanceamento ou ambiguidade. Os seis rótulos originais serão preservados para análise de erros por subtipo. A comparação multiclasse será secundária, condicionada à viabilidade de avaliar cada classe; os 65 exemplos de Pretexting não representam toda a variedade de situações reais.

Justificativa para aprendizado supervisionado

Existem exemplos rotulados e o conteúdo envolve combinações de termos além da extensão textual. No TP2, o Mann-Whitney resultou em $p \approx 0{,}1912$, com efeito pequeno: não rejeitar H0 não prova igualdade nem estabelece um limiar útil de detecção. No TP3, a regressão estima caracteres a partir de atributos de extensão; seu R^2 elevado e seu RMSE baixo refletem relações estruturais entre essas medidas, não desempenho de classificação.

Aplicar regressão linear a códigos de classe imporia ordem e distâncias arbitrárias e não garantiria probabilidades válidas. TF-IDF com regressão logística poderá aprender associações entre termos e rótulos, avaliadas por precisão, recall e F1 por classe. A regressão logística também é um método estatístico: a escolha é de um objetivo categórico supervisionado adequado, em lugar de regressão contínua ou análise descritiva isolada.

Limites e evidência necessária

Licença ainda não esclarecida, amostra pequena em inglês, possível dependência por templates e ambiguidade Phishing/Pretexting limitam a generalização. A EDA expôs toda a base; o futuro teste interno não será considerado intocado desde a origem. Será necessária avaliação externa independente, com condições de uso e anotações documentadas, próxima do atendimento bancário em português e incluindo relatos legítimos de ameaças. O planejamento detalhado está em planejamento_T2.md. Nenhum classificador foi treinado no TP3.